# Chap 2: Data Pre-processing (tt)

Nguyễn Tấn Phú ntanphu@ctuet.edu.vn

Bộ môn HTTT Khoa CNTT – Đại học Kỹ Thuật Công Nghệ Cần Thơ

#### **Outline**

- Structure data preprocessing
- Text Processing and Feature Extraction
- Images data preprocessing
- Audio, Video data preprocessing

### ☐ Importing the libraries

```
In [1]:
    import numpy as np
    import matplotlib.pyplot as plt
    import seaborn as sns
    import pandas as pd
```

#### □ Load dataset

```
In [2]: dataset = pd.read_csv('Data.csv')
In [3]: print(dataset)
# print(X)
# print(y)
```

### ☐ Output

```
Country Age Salary Purchased
   France 44.0 72000.0
                            No
    Spain 27.0 48000.0
                           Yes
  Germany 30.0 54000.0
                            No
    Spain 38.0 61000.0
                            No
  Germany 40.0
                   NaN
                           Yes
  France 35.0 58000.0
                           Yes
  Spain NaN 52000.0
                            No
  France 48.0 79000.0
                           Yes
  Germany 50.0 83000.0
                            No
9
   France 37.0 67000.0
                           Yes
```

- Xác định các feature
- X = dataset.iloc[:3, :-1] // cắt từ 3 hàng đầu và bỏ cột cuối.

```
Country Age Salary

France 44.0 72000.0

Spain 27.0 48000.0

Germany 30.0 54000.0
```

Để xử lý dữ liệu thì bạn phải chuyển về numpy array
 với hàm X = dataset.iloc[:3, :-1].values.

- □ Tiền xử lý dữ liệu
  - Xử lý Missing Data
  - Standardization (Phân phối chuẩn)
  - Handling Catogrical Variables
  - One-hot Encoding
  - Multicollinearity

#### ☐ TH1:

```
☐ TH1: Out[5]: <AxesSubplot:>
```



```
In [6]: #convert the dataframe into a numpy array by calling values
X = dataset.iloc[:, :-1].values
y = dataset.iloc[:, -1].values
```

#### ☐ TH2:

- Sử dụng thư viện Sklearn xử lý các missing data.
- SimpleImputer là một class của Sklearn hỗ trợ xử lý các missing data là số và thay chúng là một giá trị trung bình của cột, tần suất của dữ liệu suất hiện nhiều nhất ...

☐ TH2:

```
#Create an instance of Class SimpleImputer: np.nan is the empty value in the dataset
imputer = SimpleImputer(missing_values=np.nan, strategy='mean')
#Replace missing value from numerical Col 1 'Age', Col 2 'Salary'
#fit on the dataset to calculate the statistic for each column
imputer.fit(X[:, 1:3])

#The fit imputer is then applied to the dataset
# to create a copy of the dataset with all the missing values
# for each column replaced with the calculated mean statistic.
#transform will replace & return the new updated columns
X[:, 1:3] = imputer.transform(X[:, 1:3])
```

#### ☐ TH2:

```
In [8]: print(X)

[['France' 44.0 72000.0]
     ['Spain' 27.0 48000.0]
     ['Germany' 30.0 54000.0]
     ['Spain' 38.0 61000.0]
     ['Germany' 40.0 63777.7777777778]
     ['France' 35.0 58000.0]
     ['Spain' 38.77777777777778 52000.0]
     ['France' 48.0 79000.0]
     ['France' 37.0 67000.0]]
```

- ☐ Encode Independent Variables:
  - Convert một cột chứa các String thành vector 0 & 1.
  - Sử dụng ColumnTransformer class OneHotEncoder của sklearn.

### ☐ Encode Independent Variables:

Index	Animal	One-Hot code	Index	Dog	Cat	Sheep	Lion	Horse
0	Dog		0	1	0	0	0	0
1	Cat		1	0	1	0	0	0
2	Sheep		2	0	0	1	0	0
3	Horse		3	0	0	0	0	1
4	Lion		4	0	0	0	1	0

### ☐ Encode Independent Variables:

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
```

Tạo một tuple ('encoder' encoding transformation, instance của class OneHotEncoder, [cols muốn transform) và các cols khác không muốn làm gì tới nó thì có thể dùng remainder="passthrough" để bỏ qua.

```
\texttt{ct = ColumnTransformer}(\texttt{transformers=[('encoder', OneHotEncoder(), [0])] , remainder="passthrough"})
```

Fit và transform với input = X và instance ct của class
 ColumnTransformer

```
#fit and transform with input = X
#np.array: need to convert output of fit_transform() from matrix to np.array
X = np.array(ct.fit_transform(X))
```

# Encode Independent variable (X)

```
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import OneHotEncoder
#transformers: specify what kind of transformation, and which cols
#Tuple ('encoder' encoding transformation, instance of Class OneHotEncoder, [col to transform])
#remainder ="passthrough" > to keep the cols which not be transformed. Otherwise, the remaining cols
ct = ColumnTransformer(transformers=[('encoder', OneHotEncoder(), [0])] , remainder="passthrough" )
#fit and transform with input = X
#np.array: need to convert output of fit_transform() from matrix to np.array
X = np.array(ct.fit_transform(X))

print(X)
```

```
[[1.0 0.0 0.0 44.0 72000.0]
[0.0 0.0 1.0 27.0 48800.0]
[0.0 1.0 0.0 30.0 54000.0]
[0.0 1.0 0.0 38.0 61000.0]
[0.0 1.0 0.0 40.0 63777.77777777778]
[1.0 0.0 0.0 35.0 58000.0]
[0.0 0.0 1.0 38.77777777777778 52000.0]
[1.0 0.0 0.0 48.0 79900.0]
[0.0 1.0 0.0 55.0 83000.0]
[1.0 0.0 0.0 83000.0]
[1.0 0.0 0.0 57.0 67000.0]
```

Encode Dependent Variables: Sử dụng Label Encoder
 để mã hóa các nhãn

- train\_test\_split: của Sklearn-Model Selection để cắt dữ liệu train và test.
- test\_size: để chia dữ liệu tập test trên toàn bộ dữ liệu.
- random\_state = 1: Giúp sử dụng bộ random có sẵn của python.

- train\_test\_split: của Sklearn-Model Selection để cắt dữ liêu train và test.
- test\_size: để chia dữ liệu tập test trên toàn bộ dữ liệu.
- random\_state = 1: Giúp sử dụng bộ random có sẵn của python.

```
from sklearn.model selection import train test split
 X train, X test, y train, y test = train test split(X, y, test size = 0.2, random state = 1)
  print(X train)
[[0.0 0.0 1.0 38.777777777778 52000.0]
 [0.0 1.0 0.0 40.0 63777.7777777778]
 [1.0 0.0 0.0 44.0 72000.0]
 [0.0 0.0 1.0 38.0 61000.0]
 [0.0 0.0 1.0 27.0 48000.0]
 [1.0 0.0 0.0 48.0 79000.0]
 [0.0 1.0 0.0 50.0 83000.0]
 [1.0 0.0 0.0 35.0 58000.0]]
  print(X test)
[[0.0 1.0 0.0 30.0 54000.0]
```

[1.0 0.0 0.0 37.0 67000.0]]

```
In [16]: print(y_train)
       [0 1 0 0 1 1 0 1]

In [17]: print(y_test)
       [0 1]
```

# Feature Scaling (chuẩn hóa đặc trưng)

- Tại sao lại xảy ra Feature Scaling?
- Khi khai phá dữ liệu thì có thể có một số feature có độ lớn hơn hẳn các feature khác do vậy features nhỏ hơn chắc chắn sẽ bị bỏ qua khi chúng ta thực hiện ML Model.

### **Feature Scaling**

Note #1: FS không cần áp dụng cho Multi-Regression Model:

$$y = b_0 + b_1 x_1 + b_2 x_2 + b_3 x_3 + \dots + b_n x_n$$

Khi đó b<sub>0</sub>, b<sub>1</sub>, b<sub>2</sub>, b<sub>3</sub>, b<sub>n</sub> là các hệ số để bù lại cho việc chênh lệnh do vậy không cần FS

### **Feature Scaling**

 Note #2: Đối với các Categorical Features Encoding cũng không cần áp dụng FS.

```
[1.0 0.0 0.0 44.0 72000.0]
[0.0 0.0 1.0 27.0 48000.0]
[0.0 1.0 0.0 30.0 54000.0]
[55 NOT 38.0 61000.0]
[56 NOT 40.0 63777.77777777778]
[57 NOT 50.0 50.0 58000.0]
[58 NOT 50.0 58000.0]
[59 NOT 50.0 63777.777777777777778]
[50 NOT 50 NO
```

Feature Scaling.

### **Feature Scaling**

- Note #3: FS phải được thực hiện sau khi splitting Training và Test sets. Do nếu chúng ta sử dụng FS trước khi splitting training & test sets thì dữ liệu sẽ bị mất đi tính đúng.
- Vậy làm sao để Feature Scaling ?

Standardisation: Biến đổi dữ liệu sao cho giá trị trung bình là 0 và standard deviation là 1.

	Country	Age	Salary	Purchased
0	France	44.0	72000.000000	No
1	Spain	27.0	48000.000000	Yes
2	Germany	30.0	54000.000000	No
3	Spain	38.0	61000.000000	No
4	Germany	40.0	63777.777778	Yes

Từ tập dữ liệu có thể thấy số Age và Salary có độ chênh lệnh nhau khá nhiều do vậy dữ liệu của Age có thể không được sử dụng trong model. Cho nên cần chuẩn hóa dữ liệu đưa chúng về số nhỏ hơn và vẫn đảm bảo tính tương quan của dữ liệu.

$$x_{std}^{[i]} = \frac{x^{[i]} - \mu_x}{\sigma_x}$$

```
In [18]:
          from sklearn.preprocessing import StandardScaler
          sc = StandardScaler()
          X train[:,3:] = sc.fit_transform(X_train[:,3:])
          #only use Transform to use the SAME scaler as the Training Set
          X \text{ test}[:,3:] = \text{sc.transform}(X \text{ test}[:,3:])
          print(X train)
        [[0.0 0.0 1.0 -0.19159184384578545 -1.0781259408412425]
         [0.0 1.0 0.0 -0.014117293757057777 -0.07013167641635372]
         [1.0 0.0 0.0 0.566708506533324 0.633562432710455]
         [0.0 0.0 1.0 -0.30453019390224867 -0.30786617274297867]
         [0.0 0.0 1.0 -1.9018011447007988 -1.420463615551582]
         [1.0 0.0 0.0 1.1475343068237058 1.232653363453549]
         [0.0 1.0 0.0 1.4379472069688968 1.5749910381638885]
         [1.0 0.0 0.0 -0.7401495441200351 -0.5646194287757332]]
In [20]:
          print(X test)
        [[0.0 1.0 0.0 -1.4661817944830124 -0.9069571034860727]
         [1.0 0.0 0.0 -0.44973664397484414 0.2056403393225306]]
```

• Normalisation: [0, 1]

$$x_{\text{norm}} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

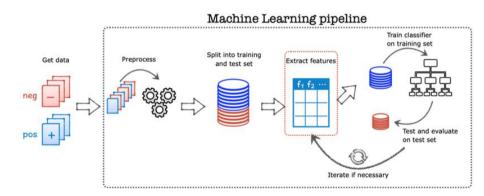
array([0., 0.2, 0.4, 0.6, 0.8, 1.])

# **Text Processing and Feature Extraction**

- Introduction
- Text preprocessing
  - Text tokenization
  - Text normalization
  - Text parsing and filtering
- Feature Extraction
  - Bag-of-Words model
  - tf-idf model

#### Introduction

# Text analysis pipeline



### **Text preprocessing**

**Goal**: Transform raw text input into normalized sequence of tokens. Prepare for feature extraction

"Hi. This is an example sentence in an Example Document."

→ [hi, example, sentence, example, document] → [1, 2, 1, 1]

### The document corpus

- A corpus contains the documents that we want to process. Each document can be accessed by a unique document label or document ID.
- The document itself is usually a (very long) character string (Python type: str) that may contain line breaks.

#### The document corpus

```
corpus = {  # document label: document text
    'spon1': 'Mehr Zustimmung zur EU auch wegen Trump - Danke May, danke Trump',
    'spon2': 'Nach Tod von US-Student Warmbier: Trump beschuldigt Nordkorea',
    'focus': 'Tod von US-Student Warmbier - Trump beschuldigt Nordkorea-Regime',
    'xyz': 'EU bleibt EU, aber EU-US-Beziehungen unter Trump weiter angespannt',
}
In [2]: # access by document label
    corpus['spon1']
```

In [1]: # a small toy corpus with some (adapted) German newspaper headlines from June 20th

Out[2]: 'Mehr Zustimmung zur EU auch wegen Trump - Danke May, danke Trump'

#### **Tokenization**

- Goal: Break down document text into smaller, meaningful components (*paragraphs*, *sentences*, *words*) → from a document, form *a list of tokens*.
- With plain Python: calling split() on a string splits it by whitespace.

```
print(corpus['xyz'].split())
['EU', 'bleibt', 'EU,', 'aber', 'EU-US-Beziehungen', 'unter', 'Trump', 'weiter', 'angespannt']
print(corpus['spon2'].split())
['Nach', 'Tod', 'von', 'US-Student', 'Warmbier:', 'Trump', 'beschuldigt', 'Nordkorea']
```

#### **Tokenization**

- str.split() might not be optimal.
- NLTK
  - √ <u>TreebankWordTokenizer</u>
  - ✓ RegExpTokenizer

### **Tokenization**

```
import nltk
# word tokenize uses TreebankWordTokenizer by default
# set language to "german" to use German punctuation
print(nltk.word tokenize(corpus['spon2'], language="german"))
['Nach', 'Tod', 'von', 'US-Student', 'Warmbier', ':', 'Trump', 'beschuldigt', 'Nordkorea']
nltk.word tokenize("I wasn't there.") # default language is English
['I', 'was', "n't", 'there', '.']
# tokenize whole corpus
tokens = {doc label: nltk.word tokenize(text, language="german")
         for doc label, text in corpus.items()}
tokens.kevs()
dict keys(['spon1', 'xyz', 'focus', 'spon2'])
print(tokens['spon1'])
['Mehr', 'Zustimmung', 'zur', 'EU', 'auch', 'wegen', 'Trump', '-', 'Danke', 'May', ',', 'danke', 'Trump']
```

#### **Text normalization**

#### ❖ Can involve:

- expanding contractions
- expanding hyphenated compound words
- removing special characters
- case conversion
- removing stopwords
- correct spelling
- stemming / lemmatization

## > The order is important!

#### Text normalization

- Expanding contractions
  - strategy: make list of all possible contractions and their expanded replacement
  - search & replace with Python using regular expressions
  - see "correct spelling" later

# **Expanding hyphenated compound words**

- How to handle words like "US-Student"?
  - leave as is
  - strip hyphens (see "removing special characters" later)
  - split by hyphens

```
# example to split by hyphen
split_tokens = []
for t in tokens['focus']:
    split_tokens.extend(t.split('-'))
print(split_tokens)

['Tod', 'von', 'US', 'Student', 'Warmbier', '-', 'Trump', 'beschuldigt', 'Nordkorea', 'Regime']
```

## Removing special characters

```
import string
string.punctuation
'!"#$%&\'()*+,-./:;<=>?@[\\]^_`{|}~'

del_chars = str.maketrans('', '', string.punctuation + '-') # add another character "-"
print([t.translate(del_chars) for t in tokens['focus']]) # apply table "del_chars"

['Tod', 'von', 'USStudent', 'Warmbier', '', 'Trump', 'beschuldigt', 'NordkoreaRegime']
```

# Especially Part-of-Speech tagging

### Removing special characters

Our strategy: Split only if first compound word is possibly longer than one character.

```
def expand compound token(t, split chars="-"):
    parts = []
    add = False # signals if current part should be appended to previous part
    for p in t.split(split chars): # for each part p in compound token t
        if not p: continue # skip empty part
        if add and parts: # append current part p to previous part
           parts[-1] += p
                            # add p as separate token
        else:
            parts.append(p)
        add = len(p) <= 1  # if p only consists of a single character -> appen
        #add = p.isupper() # alt. strateqy: if p is all uppercase ("US", "E",
    return parts
print(expand compound token("US-Student"))
print(expand compound token("Nordkorea-Regime"))
print(expand compound token("E-Mail-Provider"))
['US', 'Student']
['Nordkorea', 'Regime']
['EMail', 'Provider']
```

### Removing special characters

```
tmp_tokens = {}
for doc_label, doc_tok in tokens.items():
    tmp_tokens[doc_label] = []
    for t in doc_tok:
        t_parts = expand_compound_token(t)
        tmp_tokens[doc_label].extend(t_parts)

print('Old:', tokens['focus'])
print('New:', tmp_tokens['focus'])
tokens = tmp_tokens
```

```
Old: ['Tod', 'von', 'US-Student', 'Warmbier', '-', 'Trump', 'beschuldigt', 'Nordkorea-Regime']
New: ['Tod', 'von', 'US', 'Student', 'Warmbier', '-', 'Trump', 'beschuldigt', 'Nordkorea', 'Regime']
```

#### **Case conversion**

Usually: convert all words to lowercase.

```
print([t.lower() for t in tokens['focus']])
['tod', 'von', 'us', 'student', 'warmbier', '-', 'trump'
> str.lower(), str.upper()
```

Proper Part-of-Speech tagging might not be possible afterwards!

# **Removing stopwords**

- Stopwords are words that are removed before doing further text analysis. Usually: Very common words for a certain language that transport little information.
- Stopword list depends on:
  - Language
  - Your data / research scenario (filter out too common words)
  - Later text analysis method, e.g:
    - √ tf-idf automatically reduces importance of very common words (as opposed to Bag-of-Words)
    - ✓ sentiment analysis: bad idea to have words like "not" in the stopword list!

# **Removing stopwords**

```
print('English:', nltk.corpus.stopwords.words('english')[:5], '...')
print('German:', nltk.corpus.stopwords.words('german')[:5], '...')
English: ['i', 'me', 'mv', 'mvself', 'we'] ...
German: ['aber', 'alle', 'allem', 'allen', 'aller'] ...
# usage example (will remove "von" tokens):
stopwords = nltk.corpus.stopwords.words('german')
[t for t in tokens['focus'] if t.lower() not in stopwords]
['Tod',
 'US',
 'Student',
 'Warmbier',
 '-',
 'Trump',
 'beschuldigt',
 'Nordkorea'.
 'Regime']
```

## **Correct spelling**

- ❖ Depends on your data → especially necessary when working with social media data, surveys, etc.
- Available packages for automatic spell correction:
  - PyEnchant
  - aspell-python
  - pattern (suggest() function)

# **Stemming or Lemmatization**

❖ Goal: Reduce inflected words to a common form so that they're counted as one.

### ❖ Stemming:

 Remove affixes from a word to get base form (stem) of a word → stem might not be a lexicographically correct word

### ❖ Example:

- books → book
- booked → book
- employees → employ
- argued → argu

## **Stemming or Lemmatization**

- ❖ NLTK implements several stemming algorithms:
  - PorterStemmer, LancasterStemmer (English only)
  - SnowballStemmer (supports 13 languages)

```
stemmer = nltk.stem.LancasterStemmer()
stemmer.stem('employees')
'employ'
stemmer = nltk.stem.SnowballStemmer('german')
print('Bücher →', stemmer.stem("Bücher"))
print('gebuchte →', stemmer.stem("gebuchte"))
print('sahen →', stemmer.stem("sahen"))
Bücher → buch
gebuchte → gebucht
sahen → sah
```

### **Stemming or Lemmatization**

#### Lemmatization

 Find *lemma* (dictionary form) of a inflected word → a lemma is always a lexicographically correct word

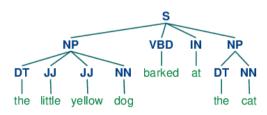
```
lemmatizer = nltk.stem.WordNetLemmatizer()
# lemmatize(): first argument is word, second is Part-of-Speech tag
print('books +', lemmatizer.lemmatize('books', 'n')) # n stands for noun
print('booked +', lemmatizer.lemmatize('booked', 'v')) # v stands for verb
print('employees +', lemmatizer.lemmatize('employees', 'n'))
print('argued +', lemmatizer.lemmatize('argued', 'v'))
books + book
```

```
books → book
booked → book
employees → employee
argued → argue
```

### **Text parsing**

### To understand text syntax and structure

- Part-of-Speech (POS) tagging → annotate words with lexical categories
- Shallow parsing / chunking → split sentences into phrases
- Dependency-based parsing
- Constituency-based parsing



# **POS tagging**

- Goal: assign a lexical category such as noun, verb, adjective, etc. to each word.
  - Needed for lemmatization
  - Optionally needed for filtering (e.g. nouns only)

```
example = ['The', 'little', 'yellow', 'dog', 'barked', 'loudly', 'at', 'the', 'cat', '.']
nltk.pos_tag(example)  # with default tagset (Penn Treebank)

[('The', 'DT'),
    ('little', 'JJ'),
    ('yellow', 'JJ'),
    ('dog', 'NN'),
    ('barked', 'VBD'),
    ('loudly', 'RB'),
    ('at', 'IN'),
    ('the', 'DT'),
    ('cat', 'NN'),
    ('cat', 'NN'),
    ('.', '.')]
```

### **POS** tagging

```
nltk.pos_tag(example, tagset='universal') # with universal tagset

[('The', 'DET'),
    ('little', 'ADJ'),
    ('yellow', 'ADJ'),
    ('dog', 'NOUN'),
    ('barked', 'VERB'),
    ('loudly', 'ADV'),
    ('at', 'ADP'),
    ('the', 'DET'),
    ('cat', 'NOUN'),
    ('.', '.')]
```

## **Text normalization summary**

- Steps from raw input text to normalized tokens:
  - 1. tokenization
  - 2. expand compound words
  - 3. POS tagging
  - 4. lemmatization
  - 5. lower-case transformation
  - 6. removing special characters
  - 7. removing stopwords </small>
- ❖ Each step involves decisions that highly effect further analyses.

# **Recommended Python packages for text preprocessing**

- NLTK: stable but slow
- Pattern: many language models but some of them only with low accuracy, Python 2.7 only
- Spacy: language models for English and partly for German and French
- SyntaxNet: many language models but difficult to install, Python 2.7 only
- Stanford CoreNLP: many language models but requires Java

#### **Feature Extraction**

- ❖ Bag-of-Words (BoW) model
- Simple but powerful model
- Features are absolute term counts
- Basis for:
  - ✓ Topic Modeling with Latent Dirichlet Allocation (LDA) via Gibbs sampling
  - ✓ Text classification with Naive Bayes, Support Vector Machines
  - ✓ Document similarity
  - ✓ Document clustering

$$C = \{D_1, D_2, D_3\}$$
 $D_1 = \{simple, yet, beautiful, example\}$ 
 $D_2 = \{beautiful, beautiful, flowers\}$ 
 $D_3 = \{example, after, example\}$ 

 $vocab = \{simple, yet, beautiful, example, flowers, after\}$ 

document	simple	yet	beautiful	example	flowers	after
$D_1$	1	1	1	1	0	0
$D_2$	0	0	2	0	1	0
$D_3$	0	0	0	2	0	1

$$M = \left(egin{array}{ccccccc} 1 & 1 & 1 & 1 & 0 & 0 \ 0 & 0 & 2 & 0 & 1 & 0 \ 0 & 0 & 0 & 2 & 0 & 1 \end{array}
ight)$$

## ❖ Example

```
from collections import Counter
example data = ['a', 'b', 'c', 'b', 'b', 'a']
example counter = Counter(example data)
example counter
Counter({'a': 2, 'b': 3, 'c': 1})
example counter.update(['c', 'a', 'a', 'a'])
example counter
Counter({'a': 5, 'b': 3, 'c': 2})
```

Normalized tokens with their POS tags are still in the variable tagged\_tokens

```
pprint(tagged tokens)
{'focus': [('tod', 'NN'),
           ('us', 'NE'),
           ('student', 'NN'),
           ('warmbier', 'NE').
           ('trump', 'FM'),
           ('beschuldigen', 'VVPP'),
           ('nordkorea', 'NE').
           ('regime', 'NN')],
 'spon1': [('zustimmung', 'NN'),
           ('eu', 'NE'),
           ('trump', 'NN'),
           ('danke', 'NE'),
           ('may', 'NE'),
           ('danke', 'PRELS'),
           ('trump', 'NE')],
```

Normalized tokens with their POS tags are still in the variable tagged\_tokens

```
'spon2': [('tod', 'NN').
         ('us', 'NE').
         ('student', 'NN').
         ('warmbier', 'NE').
         ('trump', 'NE').
          ('beschuldigen', 'VVFIN'),
         ('nordkorea', 'NE')],
'xyz': [('eu', 'NE'),
       ('bleiben', 'VVFIN'),
        ('eu', 'NE').
        ('eu', 'NE').
       ('us', 'NE'),
       ('beziehung', 'NN'),
        ('trump', 'NE'),
        ('angespannt', 'VVPP')]}
```

#### 1. Count the tokens for each document:

```
counts = {doc_label: Counter(tok) for doc_label, tok in documents.items()}
print('tokens:', documents['spon1'])
print('counts:', list(counts['spon1'].items()))
```

```
tokens: ['zustimmung', 'eu', 'trump', 'danke', 'may', 'danke', 'trump']
counts: [('may', 1), ('trump', 2), ('zustimmung', 1), ('eu', 1), ('danke', 2)]
```

#### 2. extract the vocabulary (set of unique terms in all documents):

```
vocab = set()
for counter in counts.values():
    vocab |= set(counter.kevs()) # set union of unique tokens per doc
vocab = sorted(list(vocab)) # sorting here only for better display late
vocab # => becomes columns of BoW matrix
['angespannt',
 'beschuldigen',
 'beziehung',
 'bleiben'.
 'danke'.
 'eu'.
 'mav'.
 'nordkorea'.
 'regime',
 'student',
 'tod',
 'trump'.
 'us',
 'warmbier',
 'zustimmung'l
```

### 3. Create the BoW matrix:

```
[[0, 0, 0, 0, 2, 1, 1, 0, 0, 0, 0, 2, 0, 0, 1], [1, 0, 1, 1, 0, 3, 0, 0, 0, 0, 0, 1, 1, 0, 0], [0, 1, 0, 0, 0, 0, 1, 1, 1, 1, 1, 1, 1, 0], [0, 1, 0, 0, 0, 0, 0, 1, 0, 1, 1, 1, 1, 1, 1, 0]]
```

```
doc labels = list(counts.kevs()) # => becomes rows of BoW matrix
doc labels
['spon1', 'xyz', 'focus', 'spon2']
from utils import plot heatmap
# show a heatmap of the BoW model
print('spon1:', documents['spon1'])
plot heatmap(bow, xticklabels=vocab, yticklabels=doc labels, title='BoW', save to='img/bow.png')
spon1: ['zustimmung', 'eu', 'trump', 'danke', 'may', 'danke', 'trump']
                                                 BoW
   spon1
                                       3
    xyz
   spon2
```

Terms

❖ BoW can be used in conjuction with n-grams

```
# 1-grams (unigrams):
documents['spon1']

['zustimmung', 'eu', 'trump', 'danke', 'may', 'danke', 'trump']

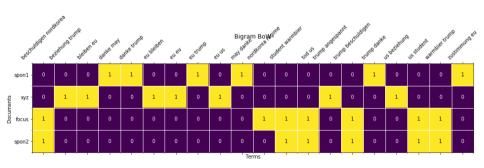
from utils import create_ngrams
# 2-grams (bigrams):
print(create_ngrams(documents['spon1'], n=2))

['zustimmung eu', 'eu trump', 'trump danke', 'danke may', 'may danke', 'danke trump']
```

Bigrams of our tokens

'danke may', 'may danke', 'danke trump']

```
from utils import create_bow
bow_bi, doc_labels_bi, vocab_bi = create_bow(documents_bigrams)
plot_heatmap(bow_bi, xticklabels=vocab_bi, yticklabels=doc_labels_bi, title='Bigram BoW');
```



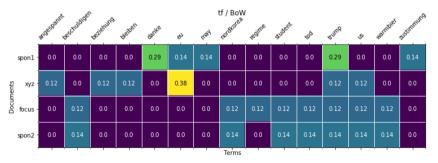
❖ TF: Term Frequency(Tần suất xuất hiện của từ) là số lần từ xuất hiện trong văn bản

$$\operatorname{tf}(t,d) = rac{\operatorname{f}(t,d)}{\max\{\operatorname{f}(w,d): w \in d\}}$$

- Trong đó:
  - tf(t, d): tần suất xuất hiện của từ t trong văn bản d
  - f(t, d): Số lần xuất hiện của từ t trong văn bản d
  - max({f(w, d) : w ∈ d}): Số lần xuất hiện của từ có số
     lần xuất hiện nhiều nhất trong văn bản d

```
import numpy as np
raw_counts = np.mat(bow, dtype=float)  # raw counts converted to NumPy matrix
tf = raw_counts / np.sum(raw_counts, axis=1) # divide by row-wise sums (document lengths) -> proportions
plot_heatmap(tf, xticklabels=vocab, yticklabels=doc_labels, title='tf / BoW', legend=True, save_to='img/tf.png');
```

#### <matplotlib.figure.Figure at 0x7fae9773eac8>



0.35

0.30

0.25

0.20

0.15

0.05

0.00

### ❖ IDF: Inverse Document Frequency

$$\operatorname{idf}(t,D) = \log rac{|D|}{|\{d \in D : t \in d\}|}$$

- Trong đó:
  - idf(t, D): giá trị idf của từ t trong tập văn bản
  - |D|: Tổng số văn bản trong tập D
  - |{d ∈ D : t ∈ d}|: thể hiện số văn bản trong tập D có chứa từ t.

$$tfidf(t, d, D) = tf(t, d) * idf(t, D)$$

- Giá trị TF-IDF cao là những từ xuất hiện nhiều trong văn bản này, và xuất hiện ít trong các văn bản khác.
- Giúp lọc ra những từ phổ biến và giữ lại những từ có giá trị cao (từ khoá của văn bản đó).

```
def num_term_in_docs(t, docs):
    return sum(t in d for d in docs.values())
num_term_in_docs('eu', documents)
```

```
from math import log

# define a function that calculates the inverse document frequency
def idf(t, docs):
    return log(1 + len(docs) / (1+num_term_in_docs(t, docs)))

idf('eu', documents)
```

0.8472978603872034

2

1.1

0.85

1.1

1.1

0.85

1.1

## Tf-idf (Term Frequency – Inverse Document Frequency)

```
idf_row = [idf(t, documents) for t in vocab]

plot_heatmap(np.mat(idf_row), vocab, title="idf(t)", ylabel=None, legend=True);

<matplotlib.figure.Figure at 0x7fae97699240>

ggetparett getputter ge
```

Terms

0.59

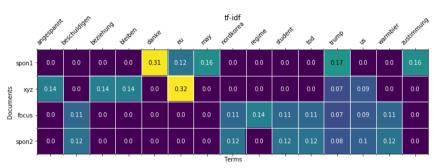
0.85

0.85

## Tf-idf (Term Frequency – Inverse Document Frequency)

```
idf mat = np.mat(np.diag(idf row))
tfidf = tf * idf mat
plot heatmap(bow. xticklabels=vocab, yticklabels=doc labels, title='BoW', legend=True, save to='img/bow.png')
plot heatmap(tfidf, xticklabels=yocab, yticklabels=doc labels, title='tf-idf', legend=True, save to='img/tfidf.png');
<matplotlib.figure.Figure at 0x7fae97477668>
                                                        RoW
   spon1
                                            3
 Socuments
     xvz
   focus
   spon2
                                                        Terms
```

## Tf-idf (Term Frequency – Inverse Document Frequency)



$$tf(danke, spon1) = 2/7 = 0.2857$$
  
 $idf(danke) = log(1 + 4/2) = 1.0986$   
 $tfidf(danke, spon1) = 0.2857 \cdot 1.0986 = 0.3139$ 

## Recommended Python packages for BoW and tf-idf

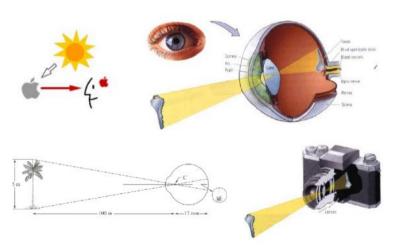
#### ❖ Gensim

- doc2bow
- TfldfModel

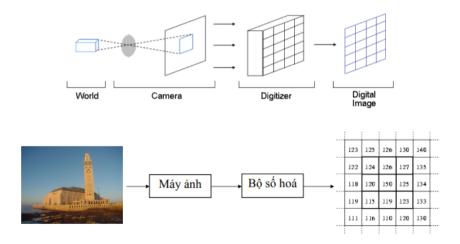
#### ❖ scikit-learn

- CountVectorizer
- TfidfVectorizer

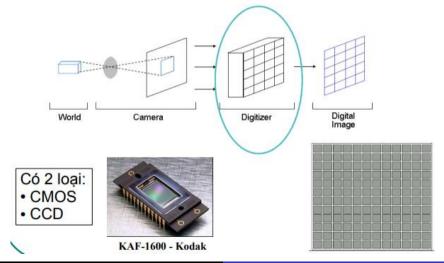
## ❖ Cơ bản về ảnh số: Quá trình thu nhận ảnh



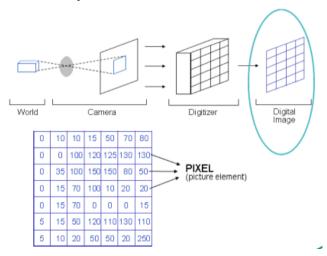
## ❖ Quá trình thu nhận ảnh



## ❖ Quá trình thu nhận ảnh



## ❖ Quá trình thu nhận ảnh

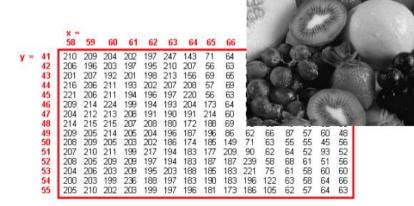


## ❖ Biểu diễn ảnh số



64	60	69	100	149	151	176	182	179
65	62	68	97	145	148	175	183	181
65	66	70	95	142	146	176	185	184
					140			
66	64	64	84	129	134	168	181	182
59	63	62	88	130	128	166	185	180
60	62	60	85	127	125	163	183	178
62	62	58	81	122	120	160	181	176
63	64	58	78	118	117	159	180	176

## ❖ Biểu diễn ảnh số



- ❖ Biểu diễn ảnh số
- Được biểu diễn bởi một ma trận 2 chiều kích thước MxN
  - Mỗi phần tử của ma trận biểu diễn 1 phần tử ảnh (pixel, hay còn gọi là điểm ảnh)
  - Giá trị (số nguyên) của phần tử biểu diễn "màu" của điểm ảnh, có giá trị trong khoảng [0, L<sub>max</sub>]
- Số bit (K) cần thiết để biểu diễn 1 "màu":

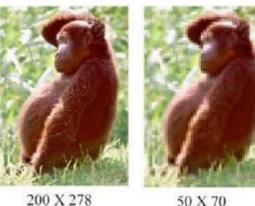
$$2^{K} \ge L_{max} \rightarrow K = ceil (log_2 L_{max})$$

Số bit cần thiết để biểu diễn 1 ảnh: b = M x N x K
Công thức để truy xuất 1 điểm ảnh ?

## ❖ Độ phân giải (resolution)

- Độ phân giải không gian
  - · Chi tiết nhỏ nhất có thể phân biệt được
- Độ phân giải màu
  - Sự thay đổi "màu" nhỏ nhất có thể phân biệt được
- Một ảnh sẽ có độ phân giải không gian là MxN pixels và có độ phân giải "màu" là K bit, hoặc L<sub>max</sub> màu.

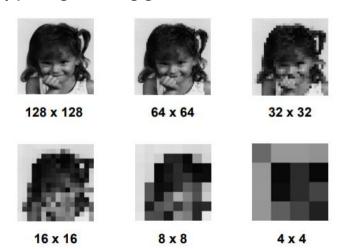
## ❖ Độ phân giải không gian



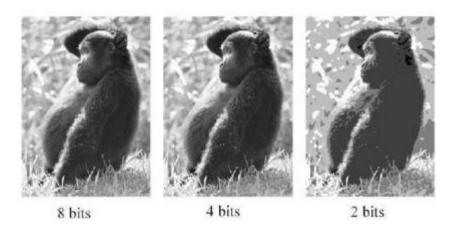


50 X 70

## ❖ Độ phân giải không gian



## ❖ Độ phân giải màu



## ❖ Độ phân giải màu



256 mức xám



16 mức xám



8 mức xám



4 mức xám



2 mức xám Ảnh nhị phân

## ❖ 3 loại ảnh số

Dựa vào "màu" của điểm ảnh, người ta phân biệt 3 loại ảnh số sau:



Ảnh mức xám



Ảnh nhị phân



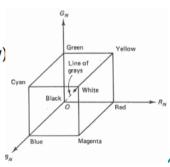
Ảnh màu

- Anh nhị phân: chỉ có 2 mức "màu" (0: đen, 1: trắng)
- Anh mức xám: có nhiều mức "màu" (0: đen, 255: trắng)
- Anh màu: được tổng hợp từ 3 màu cơ bản: R, G, B

- ❖ Ánh sáng (Light) & Màu sắc (Color)
  - Về mặt vật lý, ánh sáng là một sóng điện từ:
    - Bản chất hạt: photon
    - Bản chất sóng: tần số, độ dài bước sóng
  - Mắt người chỉ cảm nhận được các ánh sáng có bước sóng từ 380nm (tím) đến 740nm (đỏ).
  - Ánh sáng với độ dài sóng khác nhau khi tác động lên mắt người sẽ tạo nên các ý niệm về màu sắc khác nhau.

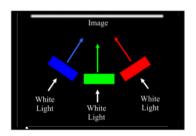
## ❖ Mô hình màu (Color model)

- Mô hình màu là một mô hình toán học trừu tượng dùng để mô tả các màu sắc thông qua các bộ số.
- Các mô hình màu thông dụng
  - RGB (Red Green Blue)
  - CMY (Cyan Magenta Yellow)
  - **HSV** (<u>H</u>ue <u>S</u>aturation <u>V</u>alue)
  - YC<sub>b</sub>C<sub>r</sub>
  - CIE



#### ❖ Mô hình màu RGB

- Các màu sắc khác nhau được tạo ra từ 3 thành phần màu cơ bản: R, G và B.
- Sự pha màu mang tính chất "cộng" (additive)





#### ❖ Mô hình màu RGB

- Mỗi màu được biểu diễn bởi một bộ ba số (R,G,B). Mỗi thành phần R,G,B là 1 số thực có giá trị từ 0 đến 1.
  - Màu đỏ (1.0, 0.0, 0.0)
  - Màu xanh lá (0.0, 1.0, 0.0)
  - Màu xanh dương (0.0, 0.0, 1.0)
  - Màu vàng (1.0, 1.0, 0.0)
  - Màu xanh lơ (0.0, 1.0, 1.0)
  - Màu tím (1.0, 0.0, 1.0)
- Màu đen (0.0, 0.0, 0.0), màu trắng (1.0, 1.0, 1.0)

- ❖ Độ sâu màu (Color depth)
  - Chế độ 24 bit: mỗi thành phần R, G, B được biểu diễn bởi một số nguyên 8 bit
    - Biểu diễn được: 256<sup>3</sup> = 16.777.216 màu
    - True color (mắt người phân biệt được 10 triệu màu)
    - Bộ nhớ cần thiết để lưu giữ hình ảnh cho 1 ảnh có độ phân giải 1024 x 768 ở chế độ 24 bit màu:
      - $1024 \times 768 \times 3 = 2.359.296 \text{ bytes} > 2MB$
  - Chế độ 32 bit: (RGBA) thêm 8 bit cho độ "trong suốt" (transparent)

- ❖ Độ sâu màu (Color depth)
- Chế độ 16 bit: mỗi thành phần R, G, B được biểu diễn bởi một số nguyên 5 bit (555 mode = 15 bit), hoặc riêng thành phần G được biểu diễn bởi 6 bit (565 mode = 16bit)
  - Biểu diễn được: 256<sup>2</sup> = 65.536 màu
  - Hi color (hiển thị hình ảnh đủ tốt)
- Chế độ 256 màu: hay ta có 8 bit để biểu diễn một màu
  - R, G, B: bao nhiêu bit ? 332 mode?

## ❖ Không gian màu CMY (CMYK)

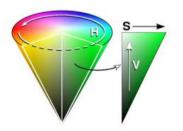
- Sử dụng 3 màu cơ bản: Cyan, Magenta, Yellow.
- Sự pha màu mang tính "<u>trừ</u>" (subtractive)
- Thường được sử dụng trong các máy in
- → Để tiết kiệm mực → thêm thành phần K (mức xám)





## Không gian màu HSV

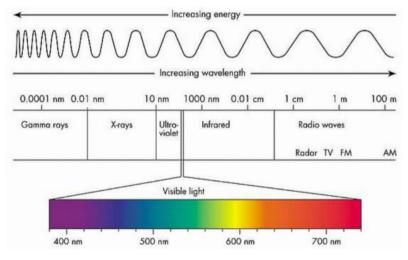
- Dùng 3 thành phần
  - H (hue): sắc thái màu (vàng, xanh, đỏ, ...)
  - S (saturation): độ bão hòa màu (đỏ, đỏ tươi, ...)
  - V (value): độ sáng (brightness) của màu



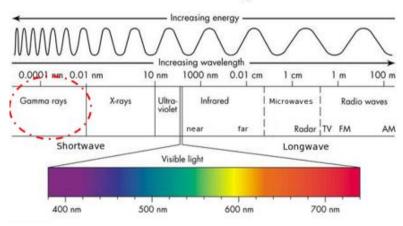


- ❖ Không gian màu YC<sub>b</sub>C<sub>r</sub>
  - > Được dùng trong ảnh JPEG, các đoạn video...
  - Thích hợp cho việc nén và giải nén dữ liệu theo tần số
  - Y: thành phần độ sáng
  - Cb và Cr: thành phần sắc thái màu
  - Mô hình màu tương tự: YUV

## ❖ Ánh sáng & Màu sắc



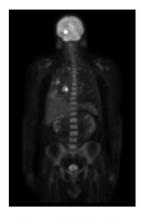
# Gamma rays



## ❖ Gamma rays



Gamma-Ray Imaging Cherenkov Telescope

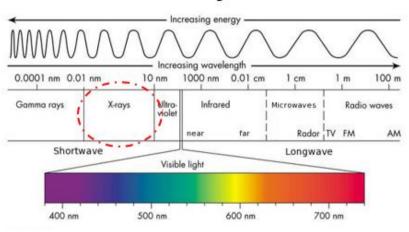


Gamma-Ray Imaging in nuclear medicine



Gamma-Ray imaging of A starburst galaxy about 12 million light-years away

# X- rays



# X- rays

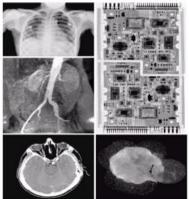
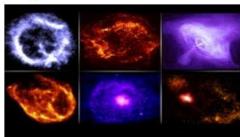
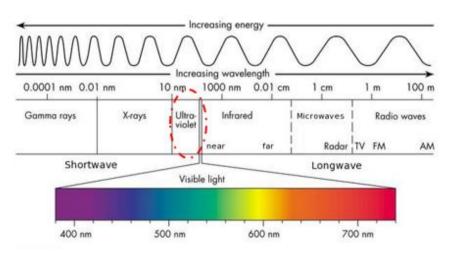


FIGURE 1.7 Examples of X-ray imaging (a) Cheel X-ray (b) Aortic angiogram, (c) Head CT. (d) Circuit boards, (e) Cygnus Looge (Images controly of (a) and (c) Dr. David R. Pickers, Diyer of Radeloogies Sciences, Valentini University Medical Certex, (b) Dr. Thomas R. Grist, Division of Amatonical Sciences, University of Michigan Medical Sciences, Sciences, University of Michigan Medical School, (d) Mr. Saccob E. Piscences, Livi, Inc., and (e) NASA. 3



X-ray images from the space The Chandra X-Ray Observatory

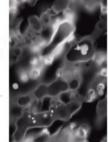
# Ultra-violet

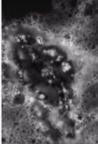


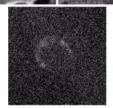
## **Ultra-violet**



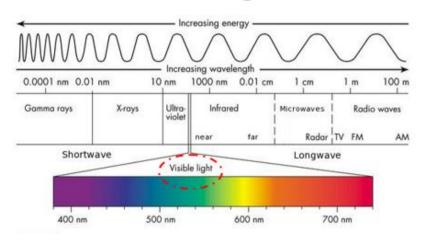
W. Davidson, Florida State University, (c) NASA.)







# Visible light



# Visible light









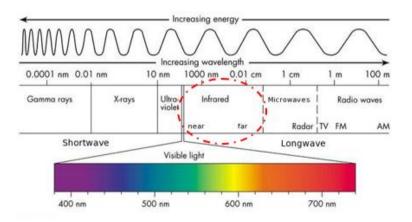




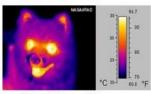




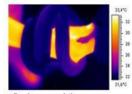
## Infrared



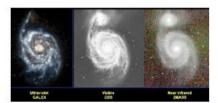
# Infrared



infrared ("thermal") image

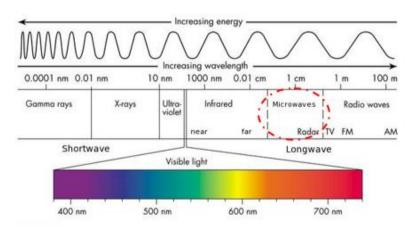


Snake around the arm



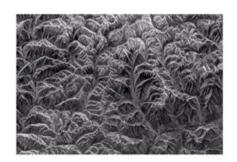
Messier 51 in ultraviolet (GALEX), visible (DSS), and near infrared (2MASS). Courtesy of James Fanson.

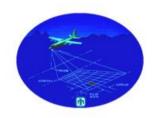
# Microwaves



# **Microwaves**

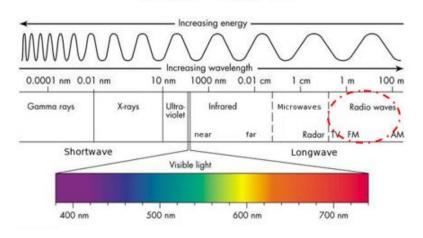
FIGURE 1.16 Spaceborne radar image of mountains in southeast Tibet. (Courtesy of NASA.)



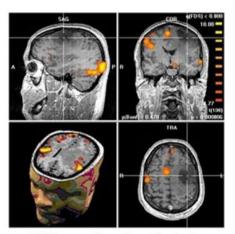


Synthetic Aperture Radar System

# Radio Waves



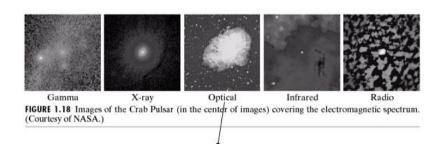
# Radio Waves



MRI image slices from the brain

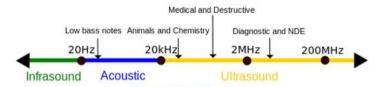
# Digital Images based on the EM Spectrum

An example showing Imaging in all of the bands



Visible light

# Ultrasound Imaging



#### Ultrasonic spectrum



Ultrasonic Baby image during pragnancy



Ultrasound image acquisition device

The continuum from image processing to computer vision can be broken up into low-, mid- and high-level processes

**High Level Process** Low Level Process Mid Level Process Input: Image Input: Image Input: Attributes Output: Image Output: Attributes Output: Understanding Examples: Scene Examples: Noise Examples: Object understanding, removal, image recognition, sharpening segmentation autonomous navigation

- Image Resizing
- 2. Noise Reduction
- 3. Color Correction
- 4. Contrast Enhancement
- 5. Segmentation
- 6. Lighting Adjustment
- Visualization
- Data Split
- 9. Data Augmentation
- 10. Normalization
- 11. Feature Extraction

# Image Resizing:

- Image resizing techniques are used to adjust the size of an image.
- Resizing can be done to make an image smaller or larger or to change its aspect ratio.
- Some typical image resizing techniques include nearest neighbor interpolation, bilinear interpolation, and bicubic interpolation

#### Noise Reduction:

- Noise in an image can be caused by various factors such as low light, sensor noise, and compression artifacts.
- Noise reduction techniques aim to remove noise from the image while preserving its essential features.
- Gaussian smoothing, median filtering, and wavelet denoising

#### Color Correction:

- Color correction techniques are used to adjust the color balance of an image.
- Color correction is important in applications such as photography, where the color accuracy of an image is critical.
- Techniques include gray world assumption, white balance, and color transfer.

#### Contrast Enhancement:

- Contrast enhancement techniques aim to increase the contrast of an image, making it easier to distinguish between different image features.
- These techniques can be helpful in applications such as medical imaging and surveillance.
- Techniques include histogram equalization, adaptive histogram equalization, and contrast stretching

# Segmentation:

- Segmentation techniques are used to divide an image into regions based on its content.
- Segmentation can be helpful in applications such as medical imaging, where specific structures or organs must be isolated from the image.
- Techniques include thresholding, edge detection, and region growing

## Data Augmentation:

 Techniques include horizontal & vertical flipping, rotation, cropping, shearing, etc.

#### ❖ Normalization

 Normalize pixel values to a common scale (e.g., 0 to 1 or -1 to 1) to make the data suitable for machine learning algorithms.

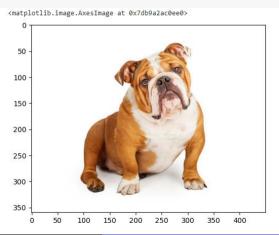
#### **Feature Extraction:** \*\*

- Feature extraction techniques are used to identify and extract relevant features from an image.
- These features can be used in object recognition and image classification applications.
- Some standard feature extraction techniques include edge detection, corner detection, and texture analysis, feature descriptors like SIFT or HOG

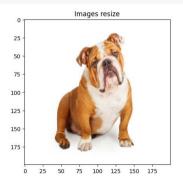
# Image processing tools:

- OpenCV.
- Scikit-image.
- PIL/pillow

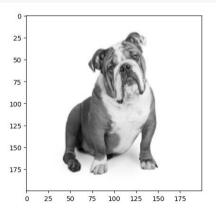
pic1 = plt.imread('/content/dog.jpg') plt.imshow(pic1)



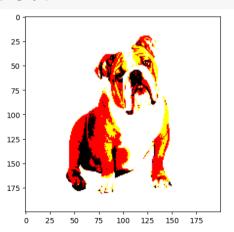
```
# setting dim of the resize
height = 200
width = 200
dim = (width, height)
res_img = cv2.resize(pic1, dim, interpolation=cv2.INTER_LINEAR)
plt.imshow(res_img), plt.title("Images resize")
plt.show()
```



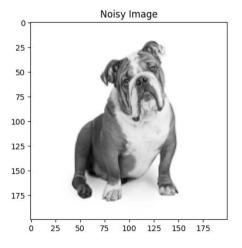
```
#Converting the sample image to grayscale
img = cv2.cvtColor(res_img, cv2.COLOR_BGR2GRAY)
plt.imshow(img,cmap='gray')
```

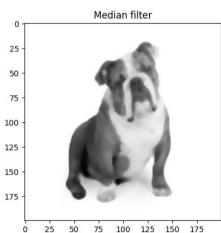


#Thresholding: try playing with the threshold value (144 here) to see the changes ret, thresh1 = cv2.threshold(res\_img, 140, 255, cv2.THRESH\_BINARY) plt.imshow(thresh1,cmap='gray')

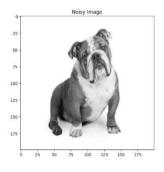


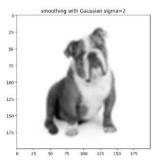
```
#Noise Reduction
#Median filter
img = cv2.cvtColor(res_img, cv2.COLOR_BGR2GRAY)
median = cv2.medianBlur(img,5)
plt.figure(figsize=(10, 10))
plt.subplot(121),plt.imshow(img,cmap = 'gray')
plt.title('Noisy Image')
plt.subplot(122),
plt.imshow(median,cmap = 'gray')
plt.title('Median filter')
plt.show()
```

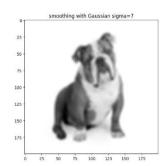




```
gaussian blur1 = cv2.GaussianBlur(img,(5,5),2,cv2.BORDER DEFAULT)
gaussian blur2 = cv2.GaussianBlur(img,(5,5),7,cv2.BORDER DEFAULT)
plt.figure(figsize=(20, 20))
plt.subplot(1,3,1),plt.imshow(img,cmap = 'gray')
plt.title('Noisv Image')
plt.subplot(1,3,2),
plt.imshow(gaussian blur1,cmap = 'gray')
plt.title('smoothing with Gaussian sigma=2')
plt.subplot(1,3,3),
plt.imshow(gaussian blur2,cmap = 'gray')
plt.title('smoothing with Gaussian sigma=7')
```

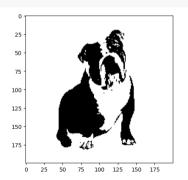


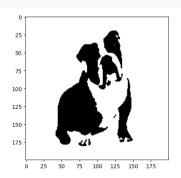




# Images data preprocessing - Otsu's Thresholding

```
#Otsu's thresholding before and after Gaussian filtering
ret2,th2 = cv2.threshold(img,0,255,cv2.THRESH_BINARY+cv2.THRESH_OTSU)
blur = cv2.GaussianBlur(img,(5,5),0)
ret3,th3 = cv2.threshold(blur,0,255,cv2.THRESH_BINARY+cv2.THRESH_OTSU)
plt.imshow(th2,cmap='gray')
plt.imshow(th3,cmap='gray')
```





# Images data preprocessing - Otsu's Thresholding

- Histogram is a visual representation of the number of pixels of each image's intensity value.
- The changes in histograms before and after applying thresholding on original and filtered images are shown below.

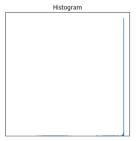
```
plt.figure(figsize=(16,16))
ret1,th1 = cv2.threshold(img,127,255,cv2.THRESH BINARY)
# Otsu's thresholding
ret2,th2 = cv2.threshold(img,0,255,cv2.THRESH BINARY+cv2.THRESH OTSU)
# Otsu's thresholding after Gaussian filtering
blur = cv2.GaussianBlur(img,(5,5),0)
ret3.th3 = cv2.threshold(blur.0.255,cv2.THRESH BINARY+cv2.THRESH OTSU)
# plot all the images and their histograms
images = [img, 0, th1,
          img. 0. th2.
          blur, 0, th31
titles = ['Original Noisy Image', 'Histogram', 'Global Thresholding (v=127)',
          'Original Noisy Image', 'Histogram', "Otsu's Thresholding",
          'Gaussian filtered Image', 'Histogram', "Otsu's Thresholding"]
for i in range(3):
    plt.subplot(3,3,i*3+1),plt.imshow(images[i*3],'gray')
    plt.title(titles[i*3]), plt.xticks([]), plt.vticks([])
    plt.subplot(3,3,i*3+2),plt.hist(images[i*3].ravel(),256)
    plt.title(titles[i*3+1]), plt.xticks([]), plt.vticks([])
    plt.subplot(3,3,i*3+3),plt.imshow(images[i*3+2],'gray')
    plt.title(titles[i*3+2]), plt.xticks([]), plt.vticks([])
plt.show()
```

Nguyễn Tấn Phú



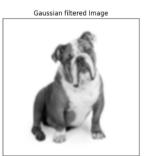


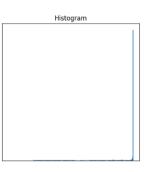








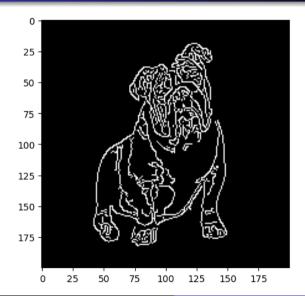






# **Images data preprocessing - Canny Edge Detection**

```
#Hough Line Transform
dst = cv2.Canny(img, 50, 200, None, 3)
lines = cv2.HoughLines(dst, 1, np.pi / 180, 150, None, 0, 0)
# Draw the lines
if lines is not None:
    for i in range(0, len(lines)):
        rho = lines[i][0][0]
        theta = lines[i][0][1]
        a = math.cos(theta)
        b = math.sin(theta)
       x0 = a * rho
        v0 = b * rho
        pt1 = (int(x0 + 1000*(-b)), int(y0 + 1000*(a)))
        pt2 = (int(x0 - 1000*(-b)), int(y0 - 1000*(a)))
        cv2.line(cdst, pt1, pt2, (0,0,255), 3, cv2.LINE AA)
cdst = cv2.cvtColor(dst, cv2.COLOR GRAY2BGR)
plt.imshow(cdst)
```



## **Images data preprocessing - Segmentation**

```
# Segmentation
grav = cv2.cvtColor(res img, cv2.COLOR RGB2GRAY)
ret. thresh = cv2.threshold(grav, 0, 255, cv2.THRESH BINARY INV + cv2.THRESH OTSU)
# Displaying segmented images
display(res img, thresh, 'Original', 'Segmented')
# Further noise removal (Morphology)
kernel = np.ones((3, 3), np.uint8)
opening = cv2.morphologyEx(thresh, cv2.MORPH OPEN, kernel, iterations=2)
# sure background area
sure bg = cv2.dilate(opening, kernel, iterations=3)
# Finding sure foreground area
dist transform = cv2.distanceTransform(opening, cv2.DIST L2, 5)
ret, sure fg = cv2.threshold(dist transform, 0.7 * dist transform.max(), 255, 0)
# Finding unknown region
sure fg = np.uint8(sure_fg)
unknown = cv2.subtract(sure bg, sure fg)
#Displaying segmented back ground
display(res img, sure bg, 'Original', 'Segmented Background')
```

# **Images data preprocessing - Segmentation**

Original



Original



Segmented



Segmented Background

